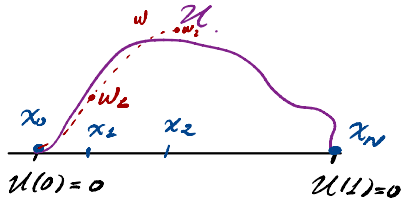
Clase 13 Análisis Numérico: Nov 13, 2026.



Sea el siguiente PVI

$$-u''(x) = f(x), \quad 0 < x < 1, \quad u(0) = u(1) = 0.$$

tomemos N subintervalos, $h = 1/N$, los nodos $x_i = ih$ y $w_i \approx u(x_i)$.

En la clase pasada vimos la fórmula del punto medio

$$u''(x_i) = \frac{u(x_{i-1}) - 2u(x_i) + u(x_{i+1})}{h^2} - \frac{h^2}{12} u^{(4)}(\xi_i).$$

Eliminando el término del error,

$$f(x_i) = -\frac{w_{i-1} + 2w_i - w_{i+1}}{h^2}; \quad i = 1, \dots, n \qquad w_0 = w_N = 0.$$

es un sistema de ecuaciones de $n = N-1$ ecuaciones.

es decir: $A\vec{x} = \vec{b}$ donde.

$$A = \frac{1}{h^2}\begin{pmatrix} 2 & -1 & & 0 \\ -1 & 2 & -1 & \\ & \ddots & \ddots & \ddots \\ & & \ddots & -1 \\ 0 & & -1 & 2 \end{pmatrix} \in \mathbb{R}^{n\times n}, \quad \vec{x} = \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix} \quad \vec{b} = \begin{pmatrix} f(x_1) \\ \vdots \\ f(x_n) \end{pmatrix}$$

Llamemos esto el problema modelo, $f(x) = e^x$. $u(x) = 1 + (e-1)x - e^x$.

Teoría Matricial:

Para hablar de convergencia de sucesión de vectores $\vec{x}^{(k)} \longrightarrow \vec{x}$ necesitamos medir distancias.

Normas Vectoriales:

Def. Una norma en $\mathbb{R}^n$ es una función $\|\cdot\| : \mathbb{R}^n \to \mathbb{R}$ tal que:

$\forall x, y \in \mathbb{R}^n$ y $\alpha \in \mathbb{R}$.

i) $\|x\| \geq 0$.

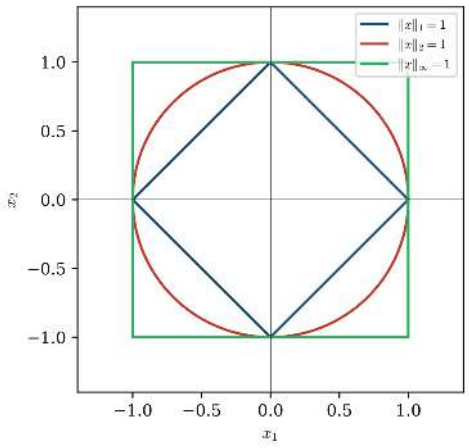
ii) $\|x\| = 0 \iff x = 0$

iii) $\|\alpha x\| = |\alpha| \|x\|$.

iv) $\|x + y\| \leq \|x\| + \|y\|$.

Ejemplos: $\|x\|_1 = \sum_{i=1}^{n} |x_i|$; $\|x\|_2 = \sqrt{\sum_{i=1}^{n} x_i^2}$; $\|x\|_\infty = \max_{1 \le i \le n} |x_i|$

Thm: (Cauchy - Schwarz) $\forall x, y \in \mathbb{R}^n \quad |x^t y| \le \|x\|_2 \|y\|_2$.



Thm: (Equivalencia de normas). $\forall x \in \mathbb{R}^n$

$$\|x\|_\infty \le \|x\|_2 \le \sqrt{n}\, \|x\|_\infty .$$

Proof: Sea j tal que $\|x\|_\infty = |x_j|$ entonces.

$$\|x\|_\infty^2 = x_j^2 \le \sum_{i=1}^{n} x_i^2 = \|x\|_2^2 \quad \text{Además.}$$

$$\|x\|_2^2 = \sum_{i=1}^{n} x_i^2 \le n\, x_j^2 = n \|x\|_\infty^2 . \qquad \blacksquare$$

Def: Una sucesión $\{x^{(k)}\}_{k \in \Lambda}$ converge a x en la norma $\|\cdot\|$ si $\|x^{(k)} - x\| \to 0$

Thm: $\vec{x}^{(k)} \longrightarrow \vec{x}$ en $\|\cdot\|_\infty \iff x_i^{(k)} \longrightarrow x_i \quad \forall i$. $\vec{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})$.

Proof $|x_i^{(k)} - x_i| \le \underbrace{\|x^{(k)} - x\|_\infty}_{\max_{1 \le j \le n} |x_j^{(k)} - x_j|} \le \sum_{i=1}^{n} |x_i^{(k)} - x_i|$. $\blacksquare$

Normas Matriciales:

Def: Una norma matricial en $\mathbb{R}^{n \times n}$ cumple las propiedades de norma y además

v). $\|AB\| \le \|A\| \|B\|$.

Thm: (Norma inducida). Si $\|\cdot\|$ norma de vectores en $\mathbb{R}^n$, entonces:

$$\|A\| = \max_{\|x\| = 1} \|Ax\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} .$$

Además, $\|Ax\| \le \|A\| \|x\|$. $\forall x$.

Proof. Si $x \neq 0$, $x/\|x\|$ es unitario y $\dfrac{\|Ax\|}{\|x\|} = \left\| A \cdot \left(\dfrac{x}{\|x\|} \right) \right\|$.

el máximo existe dado que $f: S_1^{n-1} \longrightarrow \mathbb{R}$.
$x \longmapsto \|Ax\|$ es continua.

y la esfera unitaria es compacta.

Entonces $\|Ax\| \leq \|A\|\|x\|$ por la definición de máximo.

$S_1^{n-1} = \{x \in \mathbb{R}^n \mid \|x\| = 1\}$.

Para (v). $\|ABx\| \leq \|A\|\|Bx\| \leq \|A\|\|B\|\|x\|$

$$\|AB\left(\frac{x}{\|x\|}\right)\| \leq \|A\|\|B\|$$

y tomando el máximo sobre $\|x\|=1$, tenemos que:

$$\|AB\| \leq \|A\|\|B\|.$$

□

Thm: $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^{n} |a_{ij}|$.

Proof: (Para usted)

Ejemplo: Para $A = \begin{pmatrix} 1 & 2 & -1 \\ 0 & 3 & -1 \\ 5 & -1 & 1 \end{pmatrix}$ $\begin{matrix} \longrightarrow 4 \\ \longrightarrow 4 \\ \longrightarrow 7 \end{matrix}$ $\Rightarrow \|A\|_\infty = 7$.

Valores propios y radio espectral.

Def Sea $A \in \mathbb{R}^{n \times n}$, el polinomio característico de A es $p(\lambda) = \det(A - \lambda I)$ sus raíces (algunas complejas) son valores propios de A. Si λ es valor propio y $(A - \lambda I)x = 0$, $x \neq 0$ x es vector propio.

$$\rho(A) = \max\{|\lambda| : \lambda \text{ es valor propio de } A\}.$$ radio espectral.

Thm: $\forall A \in \mathbb{R}^{n \times n}$

$$\|A\|_2 = \sqrt{\rho(A^T A)}$$

Si A es simétrica $\|A\|_2 = \rho(A)$.

Proof La matriz $A^T A$ es simétrica, por el teorema espectral $\exists (u_1, \ldots, u_n)$ base ortonormal de vectores propios y $\lambda_1, \ldots, \lambda_n$ sus valores propios cons. i.e, $\lambda_i = u_i^T A^T A u_i = \|A u_i\|_2^2 \geq 0$. Si $x = \sum_1^n c_i u_i$ entonces

$$\|x\|_2^2 = \sum_{i=1}^{n} c_i^2$$

y

$$\|Ax\|_2^2 = x^T A^T A x = \sum_{i=1}^{n} \lambda_i c_i^2 \leq \max_i \lambda_i \sum_{i=1}^{n} c_i^2 = \rho(A^T A)\,\|x\|_2^2$$

$\max_i \lambda_i = \rho(A^T A)$.

$$x^T A^T A x = (Ax)^T (Ax)$$
$$= \left(A \textstyle\sum_i c_i u_i\right)^T (Ax)$$
$$= \left(\textstyle\sum_i c_i A u_i\right)^T (Ax)$$
$$= \textstyle\sum_i c_i (Au_i)^T \cdot \left(\sum_i c_i A u_i\right)$$
$$= \textstyle\sum_i c_i^2 \underbrace{(Au_i)^T (Au_i)}_{\lambda_i}$$

Así $\|A\|_2 \leq \sqrt{\rho(A^T A)}$

Tomando x el vector propio de λ_{max} tenemos que se alcanza el valor máximo. Si A es simétrica $A^T A = A^2$ y los valores propios son λ_i^2 y

$$\sqrt{\max \lambda_i^2} = \rho(A).$$ ∎

Thm: Para toda norma natural, $\rho(A) \leq \|A\|$.

Proof. Sea λ valor propio tal que $|\lambda| = \rho(A)$ y x vector propio con $\|x\| = 1$.

Entonces

$$\rho(A) = |\lambda| = |\lambda|\,\|x\| = \|\lambda x\| = \|Ax\| \leq \|A\|\,\|x\| = \|A\|.$$ ∎

Problema: $\forall \varepsilon > 0$ existe una norma natural con $\|A\| < \rho(A) + \varepsilon$. Es decir, $\rho(A)$ es el ínfimo de todas las normas naturales de A.

Ejemplo:

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ -1 & 1 & 2 \end{pmatrix} \qquad A^T A = \begin{pmatrix} 3 & 2 & -1 \\ 2 & 6 & 4 \\ -1 & 4 & 5 \end{pmatrix}$$

$\det(A^T A - \lambda I) = -\lambda(\lambda^2 - 14\lambda + 12)$. Los valores propios son $\lambda = 0$, $\lambda = 7 \pm \sqrt{7}$.

así $\|A\|_2 = \sqrt{7 + \sqrt{7}}$. Los valores propios de A son: 0, 2 y 3. así $\rho(A) = 3$. y $\|A\|_\infty = 4$. Se cumple que $\rho(A) = 3 \leq \|A\|_2 \leq \|A\|_\infty$.

Matrices Convergentes: A es convergente si $\lim_{k \to \infty} (A^k)_{ij} = 0 \quad \forall i, j$

Ejemplo: (Norma grande no significa que no converge) Sea $A = \begin{pmatrix} \frac{1}{2} & 0 \\ 16 & \frac{1}{2} \end{pmatrix}$

$= \frac{1}{2} I + N$; $N = \begin{pmatrix} 0 & 0 \\ 16 & 0 \end{pmatrix}$ note $N^2 = 0$. y N conmuta con I

$$A^K = \left(\frac{1}{2}\right)^K I + K\left(\frac{1}{2}\right)^{K-1} N = \begin{pmatrix} 2^{-K} & 0 \\ \frac{16K}{2^{K-1}} & 2^{-K} \end{pmatrix} \xrightarrow[K\to\infty]{as} \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

$$\left(\frac{1}{2} I + N\right)^K = \sum_{i=0}^{K}{}' \binom{K}{i} \left(\frac{1}{2} I\right)^i (N)^{K-i}$$

$$= \binom{K}{K-1} \left(\frac{1}{2} I\right)^{K-1} N + \left(\frac{1}{2} I\right)^K.$$

Thm: Son equivalentes:

a). A es convergente.

b). $\lim_{K\to\infty} \|A^K\| = 0$

c). $\rho(A) < 1$.

d). $\lim_{K\to\infty} A^K x = 0 \quad \forall x$.

} ¡Para ustedes!

Lema Neumann: Si $\rho(T) < 1$, entonces $I - T$ es invertible y.

$$(I - T)^{-1} = \sum_{j=0}^{\infty}{}' T^j$$

Proof: Si $(I - T)x = 0$ entonces $Tx = x$ Si $x \neq 0$, 1 es valor propio lo que es imposible dado que $\rho(T) < 1$.

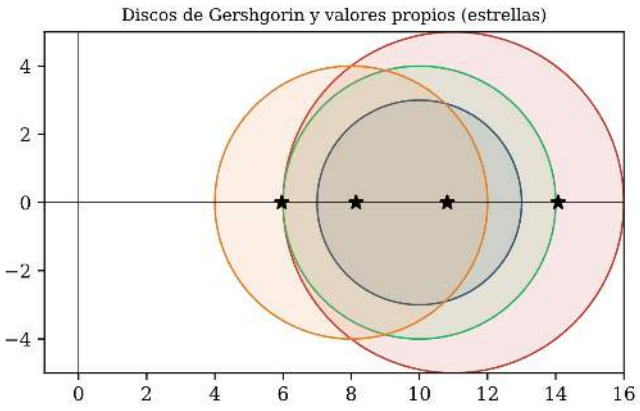
Luego $I - T$ es invertible $\ker(I - T) = \{0\}$. Sea $S_m = \sum_{j=0}^{m}{}' T^j$

Por telescopica $(I - T)S_m = I - T^{m+1} \longrightarrow I$.

Luego $S_m = (I - T)^{-1}(I - T^{m+1}) \xrightarrow[as\ m\to\infty]{} (I - T)^{-1}$. ∎

Thm: (Gershgorin) Sea R_i el disco de centro a_{ii} y radio $r_i = \sum_{j\neq i}{}' |a_{ij}|$

Todo valor propio de A esta $\bigcup_i R_i$.



Proof. Sea $Ax = \lambda x$ con $x \neq 0$.

Sea i tal que $|x_i| = \|x\|_\infty > 0$

así la fila i-ésima

$$(\lambda - a_{ii})x_i = \sum_{j \neq i}' a_{ij} x_j$$

$$(A - \lambda I)x = 0 \iff \begin{pmatrix} a_{11}-\lambda & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22}-\lambda & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{i1} & \cdots & a_{ii}-\lambda & a_{in} \\ \vdots & & & \vdots \\ a_{n1} & \cdots & & a_{nn}-\lambda \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

así que:

$$|\lambda - a_{ii}| \leq \sum_{j \neq i}' |a_{ij}| \frac{|x_j|}{|x_i|} \leq \sum_{j \neq i}' |a_{ij}| = r_i$$

$\frac{|x_j|}{|x_i|} \leq 1$

$$\iff |\lambda - a_{ii}| \leq r_i \Rightarrow \lambda \in \mathcal{B}(a_{ii}; r_i) \subseteq \bigcup R_i \quad \blacksquare$$

El espectro del problema modelo:

Rmk: Sea $A = \frac{1}{h^2}\,\text{tridiag}(-1, 2, -1)$ de orden $n = N-1$, $h = \frac{1}{N}$. $\forall k = 1, \dots, n$.

el vector $v_j^{(k)} = \sin(jk\pi h)$ es un vector propio con valor propio

$$\lambda_k = \frac{4}{h^2}\sin^2\left(\frac{k\pi h}{2}\right) \qquad k = 1, \dots, n.$$

Proof: Sea $\theta = k\pi h$ y consideremos:

$$\sin((j-1)\theta) + \sin((j+1)\theta) = 2\sin(j\theta)\cos\theta.$$

$$\left(h^2 A v^{(k)}\right)_j = -\sin((j-1)\theta) + 2\sin(j\theta) - \sin((j+1)\theta)$$

$$= 2(1 - \cos\theta)\sin(j\theta).$$

$$v_j^{(k)} = \begin{pmatrix} \vdots \\ \sin(\theta_j) \end{pmatrix}$$

$$\left(A v^{(k)}\right)_j = \frac{2}{h^2}\left(\sin(j\theta)\right)\left(\frac{1 - \cos\theta}{2}\right)2.$$

$$= \left(\frac{4}{h^2}\sin^2\left(\frac{\theta}{2}\right)\right) v_j^{(k)} = \lambda_k \cdot v_j^{(k)} \qquad \left(\lambda_k\right)_j := \frac{4}{h^2}\sin^2\left(\frac{\theta}{2}\right)$$

$\blacksquare$

Los Métodos de Jacobi y Gauss-Seidel.

Idea: Convertir $A\vec{x} = \vec{b}$ en un punto fijo.

Reescribimos $A\vec{x} = \vec{b}$ como $\vec{x} = T\vec{x} + \vec{c}$ e iteramos.

$$A\vec{x} \quad \rightsquigarrow \quad \boxed{\vec{x}^{(k)} = T\vec{x}^{(k-1)} + \vec{c}} \qquad k = 1, 2, \ldots$$

a partir de $x^{(0)}$.

El método de Jacobi: Si $a_{ii} \neq 0$, despejamos x_i de la ecuación i-th y usamos el lado derecho para iterar:

$$a_{ii}\, x_i^{(k)} = b_i - \sum_{j \neq i} a_{ij}\, x_j^{(k-1)}$$

$$x_i^{(k)} = \frac{1}{a_{ii}} \left\{ b_i - \sum_{j \neq i} a_{ij}\, x_j^{(k-1)} \right\}.$$

Ejemplo: Consideremos: con solución $\vec{x} = (1, 2, -1, 1)^T$

$$\begin{aligned} 10x_1 - x_2 + 2x_3 &= 6, \\ -x_1 + 11x_2 - x_3 + 3x_4 &= 25, \\ 2x_1 - x_2 + 10x_3 - x_4 &= -11, \\ 3x_2 - x_3 + 8x_4 &= 15. \end{aligned}$$

$$\begin{aligned} x_1^{(k)} &= \tfrac{1}{10}x_2^{(k-1)} - \tfrac{1}{5}x_3^{(k-1)} + \tfrac{3}{5}, \\ x_2^{(k)} &= \tfrac{1}{11}x_1^{(k-1)} + \tfrac{1}{11}x_3^{(k-1)} - \tfrac{3}{11}x_4^{(k-1)} + \tfrac{25}{11}, \\ x_3^{(k)} &= -\tfrac{1}{5}x_1^{(k-1)} + \tfrac{1}{10}x_2^{(k-1)} + \tfrac{1}{10}x_4^{(k-1)} - \tfrac{11}{10}, \\ x_4^{(k)} &= -\tfrac{3}{8}x_2^{(k-1)} + \tfrac{1}{8}x_3^{(k-1)} + \tfrac{15}{8}. \end{aligned}$$

Con $x^{(0)} = \vec{0}$ el primer paso da

$$x^{(1)} = \left(\tfrac{3}{5}, \tfrac{25}{11}, -\tfrac{11}{10}, \tfrac{15}{8} \right).$$

$\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|_\infty / \|\mathbf{x}^{(k)}\|_\infty < 10^{-3}$:

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$x_4^{(k)}$	$\dfrac{\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|_\infty}{\|\mathbf{x}^{(k)}\|_\infty}$	$\|\mathbf{x}^{(k)} - \mathbf{x}\|_\infty$
1	0.6000	2.2727	−1.1000	1.8750	1.0	8.8×10^{-1}
2	1.0473	1.7159	−0.8052	0.8852	5.8×10^{-1}	2.8×10^{-1}
3	0.9326	2.0533	−1.0493	1.1309	1.6×10^{-1}	1.3×10^{-1}
4	1.0152	1.9537	−0.9681	0.9738	8.0×10^{-2}	4.6×10^{-2}
5	0.9890	2.0114	−1.0103	1.0214	2.9×10^{-2}	2.1×10^{-2}
6	1.0032	1.9922	−0.9945	0.9944	1.4×10^{-2}	7.8×10^{-3}
7	0.9981	2.0023	−1.0020	1.0036	5.0×10^{-3}	3.6×10^{-3}
8	1.0006	1.9987	−0.9990	0.9989	2.4×10^{-3}	1.3×10^{-3}
9	0.9997	2.0004	−1.0004	1.0006	8.9×10^{-4}	6.2×10^{-4}

El método de Gauss-Seidel: Al calcular $x_i^{(k)}$ ya $x_1^{(k)}, \dots, x_{i-1}^{(k)}$ que son mejores que los valores viejos. Gauss-Seidel

$$x_i^{(k)} = \frac{1}{a_{ii}} \left\{ b_i - \sum_{j<i} a_{ij}\, x_j^{(k)} - \sum_{j>i} a_{ij}\, x_j^{(k-1)} \right\} \qquad i = 1, \dots, n.$$

Ejemplo 4.2 (Gauss–Seidel en el mismo sistema). Con $\mathbf{x}^{(0)} = \mathbf{0}$, el primer paso es

$$\begin{aligned}
x_1^{(1)} &= \tfrac{3}{5} = 0.6000, \qquad x_2^{(1)} = \frac{1}{a_{22}}\{ b_2 - a_{21} x_1^{(1)} - a_{23} x_3^{(0)} - a_{24} x_4^{(0)} \} \\
x_2^{(1)} &= \tfrac{1}{11}(25 + x_1^{(1)} + 0 - 0) = \tfrac{25.6}{11} = 2.3273, \qquad i = 2 \\
x_3^{(1)} &= \tfrac{1}{10}(-11 - 2x_1^{(1)} + x_2^{(1)} + 0) = \tfrac{-9.8727}{10} = -0.9873, \\
x_4^{(1)} &= \tfrac{1}{8}(15 - 3x_2^{(1)} + x_3^{(1)}) = \tfrac{7.0309}{8} = 0.8789.
\end{aligned}$$

$25 + x_2^{(1)}$; $a_{23} x_3^{(0)} - a_{24} x_4^{(0)}$: 0 0

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$x_4^{(k)}$	Cambio relativo	$\|\mathbf{x}^{(k)} - \mathbf{x}\|_\infty$
1	0.6000	2.3273	−0.9873	0.8789	1.0	4.0×10^{-1}
2	1.0302	2.0369	−1.0145	0.9843	2.1×10^{-1}	3.7×10^{-2}
3	1.0066	2.0036	−1.0025	0.9984	1.7×10^{-2}	6.6×10^{-3}
4	1.0009	2.0003	−1.0003	0.9998	2.9×10^{-3}	8.6×10^{-4}
5	1.0001	2.0000	−1.0000	1.0000	3.8×10^{-4}	9.1×10^{-5}

Cuándo converge la iteración: El teorema central.

Thm: Para todo $\vec{x}^{(0)} \in \mathbb{R}^n$, la sucesión $\vec{x}^{(k)} = T\vec{x}^{(k-1)} + \vec{c}$ converge a la única solución de $\vec{x} = T\vec{x} + \vec{c}$ si y solo si $\rho(T) < 1$.

Proof. ($\Leftarrow$) Por Lemma como $\rho(T) < 1$ $I - T$ es invertible y la ecuación $\vec{x} = T\vec{x} + \vec{c}$ tiene solución única $\{ (I - T)\vec{x} = \vec{c}. \}$

$\vec{x} = (I-T)^{-1}\vec{c}$. Restando $\vec{x} = T\vec{x} + \vec{c}$ de la iteración el error $\vec{e}^{(k)} = \vec{x}^{(k)} - \vec{x}$ cumpliendo

$$\vec{e}^{(k)} = T\vec{e}^{(k-1)} = T^2\vec{e}^{(k-2)} = \cdots = T^k\vec{e}^{(0)} \longrightarrow 0$$ dado que $\rho(T) < 1$.

($\Rightarrow$). Supongamos que hay convergencia $\forall \vec{x}^{(0)}$ y sea $\vec{x}$ el límite que cumple $\vec{x} = T\vec{x} + \vec{c}$. $\forall \vec{z} \in \mathbb{R}^n$ sea $\vec{x}^{(0)} = \vec{x} - \vec{z}$. Entonces

$$\vec{x} - \vec{x}^{(k)} = T^k(\vec{x} - \vec{x}^{(0)}) = T^k\vec{z} \longrightarrow 0.$$ Como $\vec{z}$ es arbitrario entonces $\rho(T) < 1$.

Corolario: (Cotas de error) Si $\|T\| < 1$ entonces $\forall \vec{x}^{(0)}$,

i). $\|\vec{x} - \vec{x}^{(k)}\| \leq \|T\|^k \|\vec{x}^{(0)} - \vec{x}\|$.

ii). $\|\vec{x} - \vec{x}^{(k)}\| \leq \dfrac{\|T\|^k}{1-\|T\|} \|\vec{x}^{(1)} - \vec{x}^{(0)}\|$.

Proof: i). $\|\vec{e}^{(k)}\| = \|T^k\vec{e}^{(0)}\| \leq \|T^k\|\,\|\vec{e}^{(0)}\| \leq \|T\|^k\|\vec{e}^{(0)}\|$.

ii). Como $\vec{x}^{(j+1)} - \vec{x}^{(j)} = T(\vec{x}^{(j)} - \vec{x}^{(j-1)})$.

se tiene que:

$$\|\vec{x}^{(j+1)} - \vec{x}^{(j)}\| \leq \|T^j\|\,\|\vec{x}^{(1)} - \vec{x}^{(0)}\|.$$ Así,

$$\vec{x} - \vec{x}^{(k)} = \sum_{j=k}^{\infty} (\vec{x}^{(j+1)} - \vec{x}^{(j)}) \qquad (\vec{x}^{(j)} \to \vec{x}).$$

$$\|\vec{x} - \vec{x}^{(k)}\| \leq \sum_{j=k}^{\infty} \|T\|^j \|\vec{x}^{(1)} - \vec{x}^{(0)}\|$$

$$\sum_{k=0}^{\infty} r^k = \frac{1}{1-r}.$$

$$= \|\vec{x}^{(1)} - \vec{x}^{(0)}\| \cdot \left\{ \frac{1}{1-\|T\|} - \sum_{j=0}^{k-1} \|T\|^j \right\}.$$

$$= \|\vec{x}^{(1)} - \vec{x}^{(0)}\| \cdot \left\{ \frac{1}{1-\|T\|} - \frac{1-\|T\|^k}{1-\|T\|} \right\}$$

$$= \frac{\|T\|^k}{1-\|T\|} \|\vec{x}^{(1)} - \vec{x}^{(0)}\|.$$ ∎

Algunas cosas importantes y "bonitas"

Def. A es estrictamente diagonal dominante si $|a_{ii}| > \sum_{i \neq j} |a_{ij}|$ para cada i.

Thm. Si A es estrictamente diagonal dominante, entonces A es invertible y los métodos de Jacobi y Gauss-Seidel convergen para todo $\vec{x}^{(0)}$.

Proof. *Invertible:* Por thm Geshgorin, cada disco R_i tiene centro a_{ii} y radio $r_i < |a_{ii}|$, así que no contiene el 0. Entonces 0 no es valor propio.

Jacobi: las entradas de T_J son $-a_{ij}/a_{ii}$ $j \neq i$ y 0 en la diagonal.

Así $\|T_J\|_\infty = \max_{j \neq i} \frac{|a_{ij}|}{|a_{ii}|} < 1$ y $\rho(T_J) \leq \|T_J\|_\infty < 1$.

Gauss-Seidel: Sea $\vec{x}$ con $\|\vec{x}\|_\infty = 1$, $\vec{y} = T_G \vec{x}$, i.e. $(D-L)\vec{y} = U\vec{x}$

Sea $|y_i| = \|\vec{y}\|_\infty$ en la fila i dice

$$a_{ii} y_i = -\sum_{j<i} a_{ij} y_j - \sum_{j>i} a_{ij} x_j \quad \text{entonces,}$$

$$|a_{ii}| \|\vec{y}\|_\infty \leq \sum_{j<i} |a_{ij}| \|\vec{y}\|_\infty + \sum_{j>i} |a_{ij}| \Rightarrow \|\vec{y}\|_\infty \leq \frac{\sum_{j>i} |a_{ij}|}{|a_{ii}| - \sum_{j<i} |a_{ij}|} < 1.$$

Así, $\|T_G\|_\infty < 1$ y $\rho(T_G) < 1$.

RmK: ¿Gauss-Seidel siempre es mejor?

No. Hay sistemas donde Jacobi converge y Gauss-Seidel no, y al revés.

El Teorema de Stein-Rosenberg garantiza que si $a_{ij} \leq 0$ para $i \neq j$ y $a_{ii} > 0$, entonces ambos convergen (con $\rho(T_G) < \rho(T_J) < 1$), o ambos divergen. El problema modelo cumple estas hipótesis.

El ejemplo de mal comportamiento: La matriz de Hilbert.

Def: La matriz de Hilbert de orden n es

$$H_n = \left(\frac{1}{i+j-1}\right)_{i,j=1}^{n} = \begin{pmatrix} 1 & 1/2 & 1/3 & \cdots & 1/n \\ 1/2 & 1/3 & \cdots & & 1/n+1 \\ 1/3 & \vdots & & & \vdots \\ 1/n & 1/n+1 & \cdots & & 1/2n-1 \end{pmatrix}$$

¿De dónde sale? Queremos el polinomio $p(x) = \sum_{i=0}^{n-1} a_i x^i$ que mejor aproxima f en $[0,1]$ por mínimos cuadrados, i.e. que minimiza

$$\int_0^1 (f-p)^2 dx.$$

Igualemos a 0 las derivadas respecto a cada a_i se obtienen las ecuaciones normales con matriz

$$\int_0^1 x^i x^j dx = \frac{1}{i+j+1} \qquad i,j = 0, \dots, n-1. \quad \text{que es } H_n.$$

Lo llamativo: Entradas entre 0 y 1, simétrica y definida positiva. Pero:

1). Es casi Singular:

$$\det H_2 = \frac{1}{12}, \quad \det H_3 = \frac{1}{2160}, \quad \det H_4 = \frac{1}{6048000}, \quad \det H_6 \approx 5.4 \times 10^{-18}.$$

2). Su inversa tiene entradas enteras y enormes: Por ejemplo.

$$H_3^{-1} = \begin{pmatrix} 9 & -36 & 30 \\ -36 & 192 & -180 \\ 30 & -180 & 180 \end{pmatrix}$$

La entrada más grande de H_6^{-1} es 4471000. Además, la suma de todas sus entradas es n^2 (de H_n^{-1}).

3. **Su número de condición crece exponencialmente,** aproximadamente como $e^{3.5n}$:

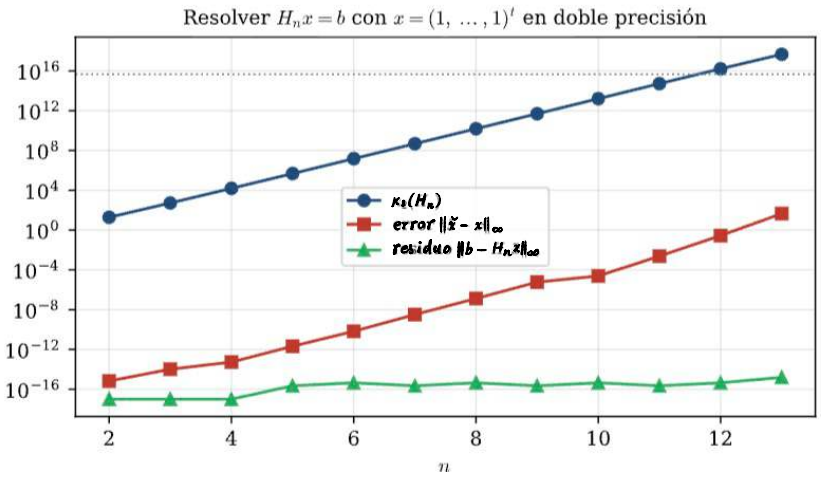
n	2	3	4	5	6
$K_\infty(H_n)$	27	748	2.8×10^4	9.4×10^5	2.9×10^7
n	7	8	9	10	
$K_\infty(H_n)$	9.9×10^8	3.4×10^{10}	1.1×10^{12}	3.5×10^{13}	

4. **El computador da un residuo perfecto y una respuesta falsa.** En la Figura 6 se resuelve $H_n \mathbf{x} = \mathbf{b}$ con $\mathbf{x} = (1, \dots, 1)^t$ en doble precisión (unas 16 cifras). Con $n = 8$ el error es 1.3×10^{-7}: se perdieron unas 10 cifras, como predice $\log_{10} K \approx 10$. Con $n = 12$, el error es 0.28 y el residuo es 4.4×10^{-16}. El computador encuentra un vector que satisface las ecuaciones casi perfectamente y que, aun así, no se parece a la solución.

¿Por qué pasa esto? En $[0,1]$, las funciones x^8, x^9 y x^{10} son casi indistinguibles: la base de monomios está formada por vectores "casi paralelos". Las columnas de H_n heredan ese casi-paralelismo, y una matriz con columnas casi paralelas está cerca de una singular.

Conexión con el curso: la razón de ser de los polinomios ortogonales

Con una base *ortogonal* (Legendre, en $[-1,1]$), la matriz de las ecuaciones normales es diagonal, su número de condición es pequeño y los coeficientes se calculan uno por uno, sin resolver ningún sistema. La matriz de Hilbert es el argumento numérico de por qué, en las Clases 9–10, cambiamos de base: no fue una elegancia teórica, sino una necesidad.



El método del Gradiente Conjugado: En esta sección A es simétrica definida positiva (SDP): $A^T = A$ y $\vec{x}^T A \vec{x} > 0 \quad \forall \vec{x} \neq 0$.

(la matriz del problema modelo lo es, porque sus valores propios son >0).

Notación: $\langle \vec{x}, \vec{y} \rangle = \vec{x}^T \vec{y}$.

Resolver un sistema es minimizar una función (♡).

Thm: Sea A (SDP) y $g(\vec{x}) = \langle \vec{x}, A\vec{x} \rangle - 2\langle \vec{x}, \vec{b} \rangle$. Entonces $\vec{x}^*$ es solución de $A\vec{x} = \vec{b}$ si y solo si $\vec{x}^*$ minimiza g en $\mathbb{R}^n$.

Proof (♡). Sean $\vec{x}, \vec{v} \in \mathbb{R}^n$, $t \in \mathbb{R}$ como A es simétrica

$$g(\vec{x} + t\vec{v}) = g(\vec{x}) - 2t\langle \vec{v}, \vec{b} - A\vec{x} \rangle + t^2 \langle \vec{v}, A\vec{v} \rangle. \quad (\star)$$

- Si $A\vec{x}^* = \vec{b}$, tomando $\vec{x} = \vec{x}^*$ en $(\star)$

$$g(\vec{x}^* + t\vec{v}) = g(\vec{x}^*) + t^2 \underbrace{\langle \vec{v}, A\vec{v} \rangle}_{\text{def positiva.}} \geq g(\vec{x}^*)$$

con igualdad solo si $t\vec{v} = \vec{0}$; $\vec{x}^*$ es el único minimizador.

- Si $\vec{x}^*$ minimiza g, la función de t en $(\star)$ tiene mínimo en $t=0$ $\forall \vec{v}$, así $\frac{d}{dt}\left(g(\vec{x}^* + t\vec{v})\right)\Big|_{t=0} = -2\langle \vec{v}, \vec{b} - A\vec{x}^* \rangle = 0 \quad \forall \vec{v}$.

tomando $\vec{v} = \vec{b} - A\vec{x}^*$ entonces $\|\vec{b} - A\vec{x}^*\|_2^2 = 0$ lo que implica que

$$A\vec{x}^* = \vec{b}$$

Como en los clases de (9-10) donde la mejor aproximación se caracterizaba por una condición de ortogonalidad, aquí un problema de minimización equivale a un sistema lineal. Además

$$\nabla g(\vec{x}) = 2(A\vec{x} - \vec{b}) = -2\vec{r}\,; \quad \vec{r} = A\vec{x} - \vec{b}.$$

el residuo apunta en dirección en que g decrece más rápido.

Buscando una dirección... Sea $\vec{x}$ fijo y una dirección $\vec{v} \neq 0$ (¿?) que es una parabola en t se minimiza en

$$t = \frac{\langle \vec{v}, \vec{r} \rangle}{\langle \vec{v}, A\vec{v} \rangle}\,; \quad \vec{r} = A\vec{x} - \vec{b}.$$

Descenso más rápido y su defecto. Sea $\vec{v}^{(k)} = \vec{r}^{(k-1)}$, la dirección de máximo descenso:

$$\vec{x}^{(k)} = \vec{x}^{(k-1)} + t_k \vec{r}^{(k-1)}, \quad t_k = \frac{\langle \vec{r}^{(k-1)}, \vec{r}^{(k-1)} \rangle}{\langle \vec{r}^{(k-1)}, A\vec{r}^{(k-1)} \rangle}.$$

Se puede demostrar que el error se reduce, en la norma $\|\vec{e}\|_A = \sqrt{\vec{e}^T A \vec{e}}$, por un factor de $\frac{K-1}{K+1}$ por paso, con $K = \lambda_{max}/\lambda_{min}$

Direcciones Conjugadas.

Def. Los vectores no nulos $\vec{v}^{(1)}, \dots, \vec{v}^{(n)}$ son A-ortogonales (o conjugados) si $\langle \vec{v}^{(i)}, A\vec{v}^{(j)} \rangle = 0 \quad \forall i \neq j$.

Thm: (♡♡) (Terminación finita). Sean $\vec{v}^{(1)}, \dots, \vec{v}^{(n)}$ direcciones A-ortogonales (claramente, l.I.), $\vec{x}^{(0)}$ arbitrario y

$$\vec{x}^{(k)} = \vec{x}^{(k-1)} + t_k \vec{v}^{(k)}, \quad t_k = \frac{\langle \vec{v}^{(k)}, \vec{b} - A\vec{x}^{(k-1)} \rangle}{\langle \vec{v}^{(k)}, A\vec{v}^{(k)} \rangle}$$

entonces $A\vec{x}^{(n)} = \vec{b}$: Con aritmética exacta se llega a la solución en $\leq n$ pasos.

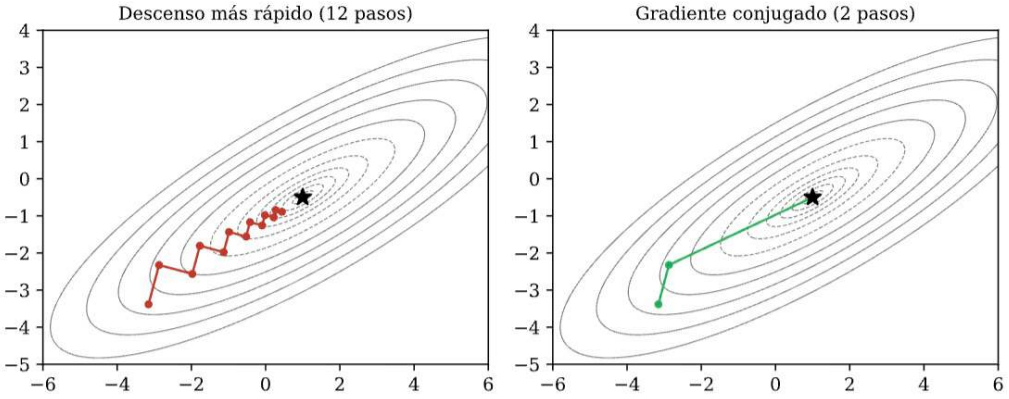


Figura 7: Curvas de nivel de g para una matriz 2×2 con $\kappa = 12$. El descenso más rápido zigzaguea y, tras 12 pasos, aún no llega al mínimo (estrella). El gradiente conjugado llega exactamente en $2 = n$ pasos.

Proof. Escribimos el error inicial en la base conjugada,

$$\vec{x}^* - \vec{x}^{(0)} = \sum_{j=1}^{n} \alpha_j \vec{v}^{(j)}. \text{ Tomemos producto con } A\vec{v}^{(k)}$$

$$\langle A\vec{v}^{(k)}, \vec{x}^* - \vec{x}^{(0)} \rangle = \langle A\vec{v}^{(k)}, \sum_{j=1}^{n} \alpha_j \vec{v}^{(j)} \rangle$$

$$= \alpha_k \langle A\vec{v}^{(k)}, \vec{v}^{(k)} \rangle$$

lo que implica que

$$\alpha_k = \frac{\langle \vec{v}^{(k)}, A(\vec{x}^* - \vec{x}^{(0)}) \rangle}{\langle \vec{v}^{(k)}, A\vec{v}^{(k)} \rangle} \qquad (A \text{ es simétrica})$$

Veamos que $\alpha_k = t_k$: Como $\vec{x}^{(k-1)} = \vec{x}^{(0)} + \sum_{j<k} t_j \vec{v}^{(j)}$ entonces $\vec{b} - A\vec{x}^{(k-1)} = \vec{b} - A\vec{x}^{(0)} - \sum_{j<k} t_j A\vec{v}^{(j)}$. y al hacer el producto con $\vec{v}^{(k)}$ los términos de la suma se anulan por A-ortogonal. Así, $\langle \vec{v}^{(k)}, \vec{b} - A\vec{x}^{(k-1)} \rangle = \langle \vec{v}^{(k)}, \vec{b} - A\vec{x}^{(0)} \rangle$ y $t_k = \alpha_k$. Por tanto,

$$\vec{x}^{(n)} = \vec{x}^{(0)} + \underbrace{\sum_{k} \alpha_k \vec{v}^{(k)}}_{\vec{x}^* - \vec{x}^{(0)}} = \vec{x}^* \qquad \blacksquare$$